PCA, SVD et décompositions matricielles

Guide ciblé Hedge Funds, Alpha Research et ML Quant

Un guide compact pour comprendre les objets, dériver les résultats importants, choisir le bon algorithme numérique et expliquer l'utilité financière de chaque méthode.

P0 À dériver et expliquer sans notes : PCA, lien avec SVD, least squares, stabilité numérique.

P1 À savoir choisir et utiliser : LU, QR, Cholesky, pseudoinverse, ridge, rolling PCA.

P2 À reconnaître : randomized/incremental PCA, whitening avancé, rotations de sous-espaces.

Réflexe entretien : définir les dimensions, l'objectif mathématique, les hypothèses, le coût numérique et l'erreur évitée. Ne jamais dire seulement « on applique PCA ».

Contents

1 Carte mentale et objets **2**
1.1 Spectre, rang et conditionnement [P0] . . . 2

2 PCA : idée et dérivation **2**
2.1 Ce que PCA construit [P0] . . . 3
2.2 Dérivation par maximisation de variance [P0] . . . 3
2.3 Scores, loadings et variance expliquée [P0] . . . 3

3 PCA : géométrie, reconstruction et exemple **3**
3.1 Reconstruction de rang k [P0] . . . 4
3.2 Petit exemple exact [P0] . . . 4
3.3 Covariance ou corrélation ? [P0] . . . 4

4 Applications en HF, alpha research et ML quant **5**
4.1 Facteurs de rendement et risque [P0] . . . 5
4.2 Features, signaux et exécution [P0/P1] . . . 5
4.3 Validation et erreurs fréquentes [P0] . . . 6

5 SVD : définition et lien exact avec PCA **6**
5.1 Définition [P0] . . . 6
5.2 PCA par SVD [P0] . . . 6
5.3 Truncated SVD et Eckart–Young [P0/P1] . . . 6

6 SVD, least squares, pseudoinverse et ridge **7**
6.1 Least squares et pseudoinverse [P0] . . . 7
6.2 Ridge vu dans la base SVD [P0] . . . 7
6.3 Pourquoi ne pas inverser la matrice des normal equations ? [P0] . . . 8

7 QR : le solveur naturel du least squares **8**

8 LU : résoudre des systèmes carrés efficacement **8**
8.1 Définition et pivoting [P0/P1] . . . 8
8.2 Résoudre un système linéaire [P0] . . . 8
8.3 À quoi LU sert réellement [P0/P1] . . . 9

9 Cholesky et matrices de covariance **9**

10 Quel outil choisir ? **9**
10.1 Whitening [P1] . . . 10
10.2 Coût, latence et production [P1] . . . 10

11 Workflow appliqué à un projet quant **10**

12 Cheat sheet entretien **10**

1 Carte mentale et objets

Objectif. Donner un rôle précis à chaque matrice avant toute formule.

On observe n lignes et p variables :

$$X \in \mathbb{R}^{n\times p}, \qquad X_{ij} = \text{valeur de la variable } j \text{ pour l'observation } i.$$

On note $\mathbf{1}_n \in \mathbb{R}^n$ le vecteur rempli de 1 et $\mu \in \mathbb{R}^p$ le vecteur des moyennes, avec $\mu_j = n^{-1}\sum_{i=1}^n X_{ij}$. Alors

$$X_c = X - \mathbf{1}_n\mu^\mathsf{T}, \qquad S = \frac{1}{n-1}X_c^\mathsf{T}X_c \in \mathbb{R}^{p\times p}$$

sont respectivement la matrice centrée et la covariance empirique.

Notations. A^T est la transposée de A; I_d est l'identité de taille d; $\|x\|_2$ est la norme euclidienne, $\|A\|_F^2 = \sum_{ij} A_{ij}^2$ la norme de Frobenius et $\|A\|_2 = \sigma_{\max}(A)$ la norme spectrale. Enfin, $\operatorname{rank}(A)$ est le nombre de directions linéairement indépendantes de A.

Dans le tableau suivant, $A \in \mathbb{R}^{d\times d}$ désigne une matrice carrée et $b \in \mathbb{R}^d$ un second membre.

Méthode	Question résolue	Usage quant principal
PCA	Quelles directions résument la variance ?	Facteurs, réduction de dimension, risque, débruitage
SVD	Quelles directions de X sont fortes ou faibles ?	PCA stable, rang, pseudoinverse, least squares
QR	Comment résoudre un least squares stablement ?	Régressions et orthogonalisation
LU	Comment résoudre rapidement $Ax = b$?	Systèmes carrés généraux, plusieurs seconds membres
Cholesky	Même question si A est symétrique définie positive	Covariances, simulations, optimisation

Règle fondamentale : résoudre $Ax = b$ ne signifie pas calculer A^{-1}. Une factorisation suivie de substitutions est généralement plus rapide et plus stable.

1.1 Spectre, rang et conditionnement [P0]

Le **spectre** d'une matrice carrée est l'ensemble de ses valeurs propres. Pour une matrice symétrique S :

$$S = V\Lambda V^\mathsf{T}, \qquad V^\mathsf{T}V = I_p, \qquad \Lambda = \operatorname{diag}(\lambda_1, \dots, \lambda_p).$$

Les colonnes v_i de $V = [v_1, \dots, v_p]$ sont les vecteurs propres orthonormés et les λ_i, ordonnées $\lambda_1 \geq \cdots \geq \lambda_p$, les valeurs propres correspondantes. Si S est une covariance, alors $\lambda_i \geq 0$. Le rang est le nombre de valeurs propres non nulles. Si S est inversible,

$$S^{-1} = V\Lambda^{-1}V^\mathsf{T},$$

donc ses valeurs propres deviennent $1/\lambda_i$.

Le conditionnement spectral de X est

$$\kappa_2(X) = \frac{\sigma_{\max}(X)}{\sigma_{\min}(X)}.$$

$\sigma_{\max}(X)$ et $\sigma_{\min}(X)$ sont les plus grande et plus petite valeurs singulières de X. Cette définition suppose que X est de rang plein; sinon $\sigma_{\min}(X) = 0$ et $\kappa_2(X) = +\infty$. Une grande valeur signifie qu'une faible perturbation des données peut produire une forte variation de la solution d'un problème linéaire utilisant X.

2 PCA : idée et dérivation

Objectif. Remplacer p variables corrélées par quelques combinaisons linéaires orthogonales qui conservent le maximum de variance.

2.1 Ce que PCA construit [P0]

Une direction $w \in \mathbb{R}^p$ avec $\|w\|_2 = 1$ définit un score

$$z = X_c w \in \mathbb{R}^n.$$

Chaque score est une combinaison linéaire des variables. Sa variance empirique est

$$\mathrm{Var}(z) = \frac{1}{n-1}\|X_c w\|_2^2 = w^\mathsf{T} S w.$$

PCA cherche d'abord la direction de variance maximale, puis des directions orthogonales aux précédentes.

2.2 Dérivation par maximisation de variance [P0]

Première composante :

$$\max_{w \in \mathbb{R}^p} w^\mathsf{T} S w \quad \text{sous} \quad w^\mathsf{T} w = 1.$$

Lagrangien :

$$\mathcal{L}(w, \lambda) = w^\mathsf{T} S w - \lambda(w^\mathsf{T} w - 1).$$

Condition du premier ordre :

$$\nabla_w \mathcal{L} = 2Sw - 2\lambda w = 0 \quad \Longrightarrow \quad Sw = \lambda w.$$

La variance obtenue vaut $w^\mathsf{T} S w = \lambda$. Il faut donc choisir l'eigenvecteur associé à la plus grande valeur propre. Les composantes suivantes utilisent les valeurs propres décroissantes avec contraintes d'orthogonalité.

Réponse courte : PCA diagonalise la covariance. Les eigenvecteurs sont les directions principales; les eigenvalues sont les variances portées par ces directions.

2.3 Scores, loadings et variance expliquée [P0]

Pour $1 \le k \le \mathrm{rank}(S)$, on rassemble les k premiers vecteurs propres dans $V_k = [v_1, \ldots, v_k] \in \mathbb{R}^{p \times k}$:

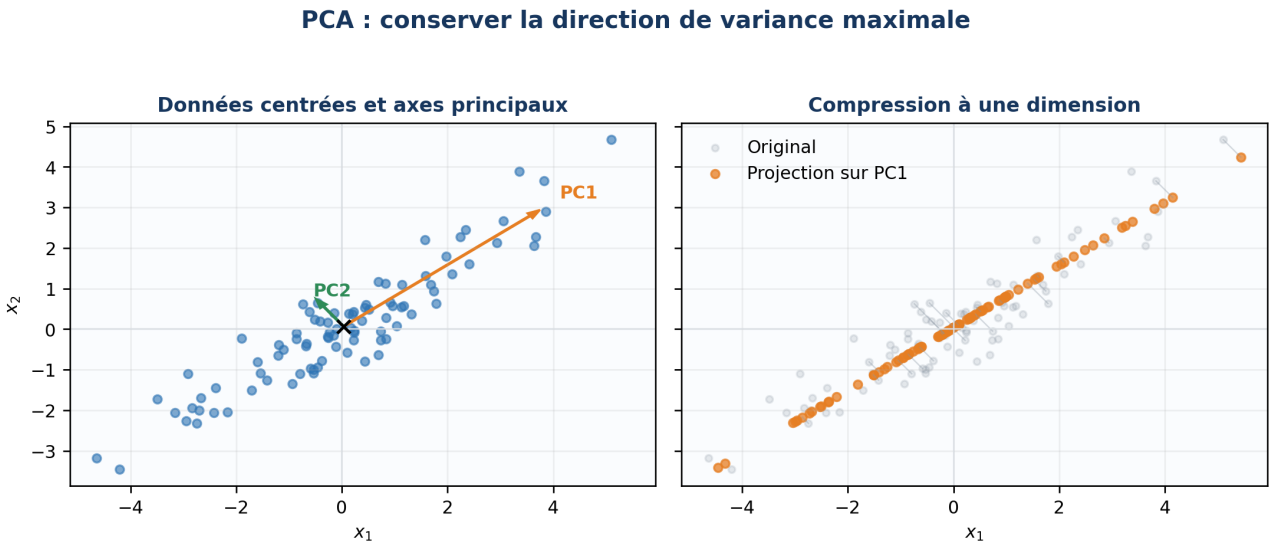
$$Z = X_c V_k \in \mathbb{R}^{n \times k}.$$

- **Loadings V_k :** poids des variables dans chaque direction. Convention utilisée ici.
- **Scores Z :** coordonnées des observations dans le nouvel espace.
- **Variance de PC i :** λ_i.
- **Ratio expliqué :** $\lambda_i / \sum_{j=1}^{p} \lambda_j$.

Attention : certains logiciels appellent « loadings » les quantités $v_i\sqrt{\lambda_i}$. Toujours annoncer la convention.

3 PCA : géométrie, reconstruction et exemple

Objectif. Comprendre ce qui est conservé, ce qui est perdu et comment mesurer cette perte.



3.1 Reconstruction de rang k [P0]

La projection et la reconstruction sont

$$Z = X_c V_k, \qquad \widehat{X}_c = X_c V_k V_k^{\mathsf{T}}, \qquad \widehat{X} = \widehat{X}_c + \mathbf{1}_n \mu^{\mathsf{T}}.$$

PCA choisit le sous-espace qui minimise l'erreur quadratique de reconstruction :

$$\min_{\operatorname{rank}(\widehat{X}_c) \le k} \|X_c - \widehat{X}_c\|_F^2.$$

Pour PCA,

$$\frac{1}{n-1}\|X_c - X_c V_k V_k^{\mathsf{T}}\|_F^2 = \sum_{j=k+1}^{p} \lambda_j.$$

Garder k composantes signifie donc accepter précisément la variance des directions supprimées.

3.2 Petit exemple exact [P0]

Supposons que la covariance estimée soit

$$S = \begin{pmatrix} 4 & 3 \\ 3 & 4 \end{pmatrix}.$$

Alors

$$\lambda_1 = 7, \quad v_1 = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ 1 \end{pmatrix}, \qquad \lambda_2 = 1, \quad v_2 = \frac{1}{\sqrt{2}}\begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

PC1 représente le mouvement commun et explique

$$\frac{7}{7+1} = 87.5\%.$$

Pour l'observation centrée $x = (2, 0)^{\mathsf{T}}$:

$$z_1 = v_1^{\mathsf{T}} x = \sqrt{2}, \qquad \widehat{x} = z_1 v_1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

La reconstruction conserve le mouvement commun et supprime le contraste $(1, -1)^{\mathsf{T}}$.

3.3 Covariance ou corrélation ? [P0]

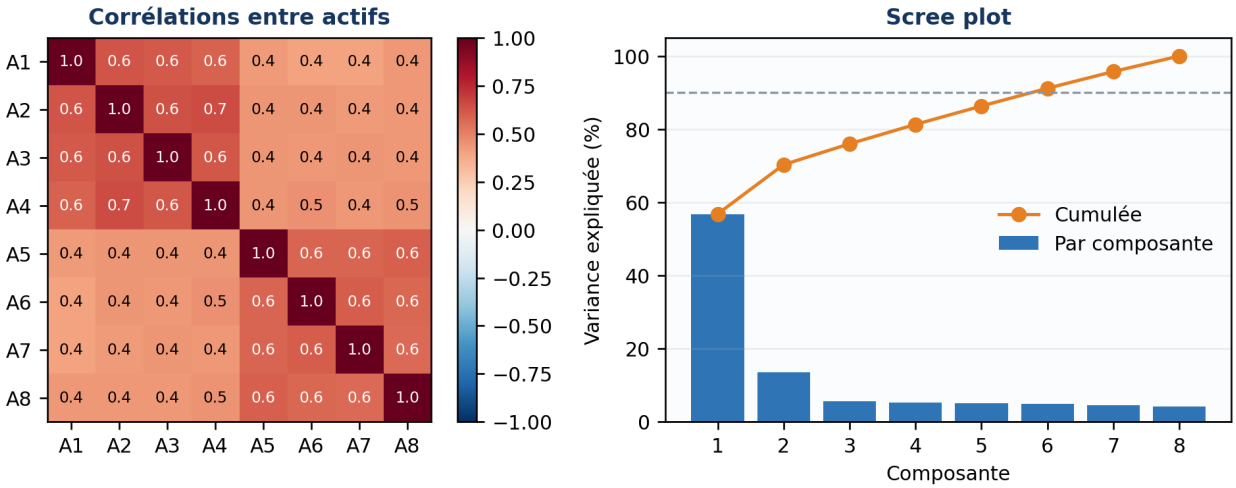
- **PCA sur covariance :** les variables à forte variance dominent; utile si les unités et échelles ont un sens commun, par exemple des rendements comparables.
- **PCA sur corrélation :** standardiser chaque colonne; utile lorsque les échelles diffèrent ou que l'on veut donner un poids initial comparable aux variables.

Le scaling est une décision de modèle, pas un détail de preprocessing.

4 Applications en HF, alpha research et ML quant

Objectif. Utiliser PCA comme représentation et contrôle de risque, sans la confondre avec un modèle prédictif.

Exemple cross-asset simulé : facteurs communs et dimension effective



4.1 Facteurs de rendement et risque [P0]

Pour une matrice de rendements centrés $R \in \mathbb{R}^{T\times N}$:

$$S = \frac{1}{T-1} R^{\mathsf{T}} R = V \Lambda V^{\mathsf{T}}.$$

Ici, T est le nombre de dates et N le nombre d'actifs. Les factor returns PCA sont $F = RV_k \in \mathbb{R}^{T\times k}$. PC1 ressemble souvent à un facteur marché, puis peuvent apparaître secteurs, styles ou spreads; cette interprétation doit être vérifiée, jamais imposée.

Pour un vecteur de poids de portefeuille $q \in \mathbb{R}^N$ et le vecteur aléatoire de rendements $r \in \mathbb{R}^N$, poser $a = V^{\mathsf{T}} q$, où a_i est l'exposition du portefeuille à la composante i. Alors

$$\mathrm{Var}(q^{\mathsf{T}} r) = q^{\mathsf{T}} S q = \sum_{i=1}^{N} \lambda_i a_i^2.$$

On voit quelles composantes portent le risque. Pour retirer les k premiers facteurs en géométrie euclidienne :

$$q_\perp = (I_N - V_k V_k^{\mathsf{T}}) q.$$

En pratique, coûts, contraintes et neutralités sont ajoutés dans une optimisation.

4.2 Features, signaux et exécution [P0/P1]

- **Réduction de dimension :** compresser des features très collinéaires avant une régression.
- **Débruitage :** reconstruire avec les composantes stables, mais ne pas supprimer automatiquement les petites directions : un alpha peut vivre dans une faible variance.
- **Residualisation :** rechercher du relative value hors des facteurs communs dominants.
- **Order book :** compresser plusieurs niveaux de profondeur, spreads et imbalances corrélés.
- **Monitoring :** suivre variance expliquée, sous-espace factoriel et résidus pour détecter un régime.

PCA est **non supervisée** : elle maximise la variance de X, pas la prévisibilité de Y ni le Sharpe. La direction la plus volatile peut être inutile; une direction faible peut contenir le signal.

4.3 Validation et erreurs fréquentes [P0]

- ajuster moyenne, scaling et loadings uniquement sur le train;
- appliquer cette transformation figée à validation/test;
- utiliser rolling ou expanding PCA si la structure change;
- aligner le signe : pour un loading suivi dans le temps, remplacer v_t par $-v_t$ si $v_t^\top v_{t-1} < 0$;
- si $\lambda_i \approx \lambda_{i+1}$, les vecteurs individuels sont instables même si leur sous-espace est stable;
- contrôler outliers, missing data, survivorship et changements d'univers;
- sélectionner k par validation, stabilité et utilité économique, pas seulement par un seuil de 95%.

5 SVD : définition et lien exact avec PCA

Objectif. Décomposer directement la matrice de données pour révéler son rang, ses directions fortes et sa stabilité numérique.

5.1 Définition [P0]

Pour $X \in \mathbb{R}^{n\times p}$ de rang r, la SVD réduite est

$$\boxed{X = U\Sigma V^\top}$$

avec

$$U \in \mathbb{R}^{n\times r}, \quad U^\top U = I_r, \qquad V \in \mathbb{R}^{p\times r}, \quad V^\top V = I_r,$$
$$\Sigma = \operatorname{diag}(\sigma_1, \dots, \sigma_r), \qquad \sigma_1 \geq \cdots \geq \sigma_r > 0.$$

Les colonnes u_i de U sont les vecteurs singuliers gauches, les colonnes v_i de V les vecteurs singuliers droits, et les σ_i les valeurs singulières positives. Le nombre $r = \operatorname{rank}(X) \leq \min(n, p)$ est le rang de X. Géométriquement : $V^\top$ tourne les directions d'entrée, Σ les étire, puis U les place dans l'espace de sortie.

5.2 PCA par SVD [P0]

Appliquons la SVD à la matrice centrée :

$$X_c = U\Sigma V^\top.$$

Alors

$$S = \frac{1}{n-1} X_c^\top X_c = V \frac{\Sigma^2}{n-1} V^\top.$$

Donc :

$$\text{loadings PCA} = V, \qquad \lambda_i = \frac{\sigma_i^2}{n-1}, \qquad \text{scores} = X_c V = U\Sigma.$$

On préfère souvent calculer PCA avec SVD de X_c plutôt qu'en formant $X_c^\top X_c$: on évite de carrer le conditionnement et on travaille mieux lorsque $p > n$.

5.3 Truncated SVD et Eckart–Young [P0/P1]

Pour $1 \leq k < r$, la meilleure approximation de rang k est

$$X_k = U_k \Sigma_k V_k^\top.$$

Ici, U_k et V_k contiennent les k premiers vecteurs singuliers et $\Sigma_k = \operatorname{diag}(\sigma_1, \dots, \sigma_k)$. Elle vérifie

$$\|X - X_k\|_F^2 = \sum_{i>k} \sigma_i^2, \qquad \|X - X_k\|_2 = \sigma_{k+1}.$$

C'est la justification formelle de la compression PCA. Pour de très grandes matrices creuses, randomized SVD approxime seulement les premières directions à moindre coût.

6 SVD, least squares, pseudoinverse et ridge

Objectif. Voir exactement pourquoi la collinéarité rend une régression instable et comment la régularisation la corrige.

6.1 Least squares et pseudoinverse [P0]

Pour $y \in \mathbb{R}^n$, $X \in \mathbb{R}^{n \times p}$ et $\beta \in \mathbb{R}^p$, on minimise

$$\min_{\beta} \|y - X\beta\|_2^2.$$

Avec $X = U\Sigma V^\mathsf{T}$ et rang colonne complet ($r = p$) :

$$\widehat{\beta}_{OLS} = V\Sigma^{-1}U^\mathsf{T}y = \sum_{i=1}^{r} \frac{u_i^\mathsf{T} y}{\sigma_i} v_i.$$

Une petite σ_i amplifie fortement le bruit dans $u_i^\mathsf{T} y$.

La pseudoinverse de Moore–Penrose est

$$X^+ = V\Sigma^+ U^\mathsf{T},$$

où $\Sigma^+ = \mathrm{diag}(1/\sigma_1, \ldots, 1/\sigma_r)$ inverse seulement les valeurs singulières non nulles. Elle donne une solution least squares et, si plusieurs solutions existent, celle de norme minimale.

6.2 Ridge vu dans la base SVD [P0]

Ridge minimise

$$\|y - X\beta\|_2^2 + \lambda\|\beta\|_2^2$$

et donne

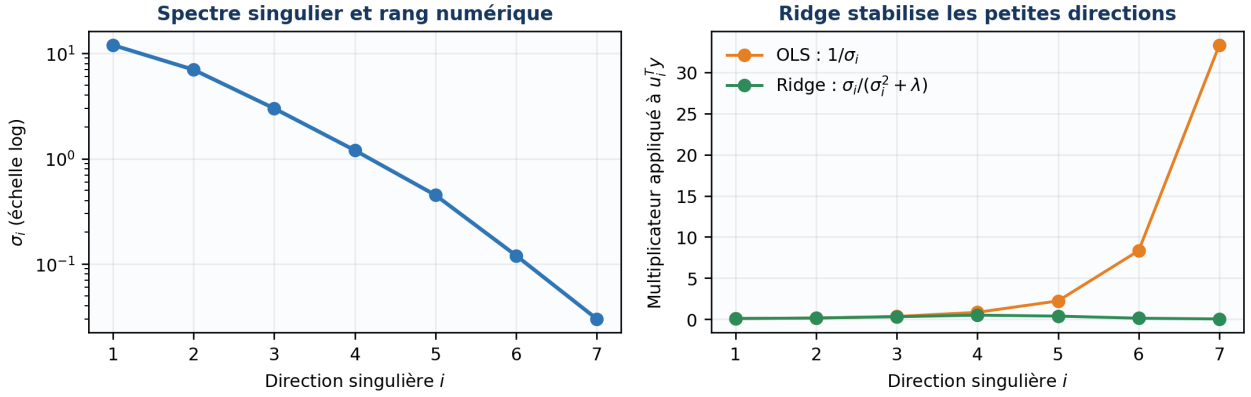
$$\widehat{\beta}_{ridge} = V\,\mathrm{diag}\left(\frac{\sigma_i}{\sigma_i^2 + \lambda}\right) U^\mathsf{T} y.$$

Comparaison par direction :

$$\text{OLS} : \frac{1}{\sigma_i}, \qquad \text{Ridge} : \frac{\sigma_i}{\sigma_i^2 + \lambda}.$$

$\lambda \geq 0$ est le paramètre de régularisation : plus il est grand, plus les coefficients sont contractés.

Pourquoi les petites valeurs singulières rendent OLS instable



Ridge réduit surtout les directions mal identifiées. Il introduit du biais mais diminue souvent fortement la variance hors échantillon.

6.3 Pourquoi ne pas inverser la matrice des normal equations ? [P0]

Si X est de rang colonne plein, les normal equations donnent formellement

$$\widehat{\beta} = (X^\mathsf{T} X)^{-1} X^\mathsf{T} y,$$

mais, dans ce même cas,

$$\kappa_2(X^\mathsf{T} X) = \kappa_2(X)^2.$$

Former $X^\mathsf{T} X$ perd donc davantage de précision. En code : QR pour un least squares standard, SVD si rang déficient ou très mal conditionné, ridge si la régularisation est justifiée statistiquement.

7 QR : le solveur naturel du least squares

Objectif. Résoudre une régression sans former $X^\mathsf{T} X$ et sans payer le coût complet d'une SVD.

Pour une matrice tall $X \in \mathbb{R}^{n \times p}$ avec $n \geq p$:

$$X = QR, \qquad Q \in \mathbb{R}^{n \times p}, \quad Q^\mathsf{T} Q = I_p, \qquad R \in \mathbb{R}^{p \times p} \text{ triangulaire supérieure.}$$

Alors

$$\|y - X\beta\|_2^2 = \|Q^\mathsf{T} y - R\beta\|_2^2 + \|(I_n - QQ^\mathsf{T})y\|_2^2.$$

Il suffit de résoudre

$$R\widehat{\beta} = Q^\mathsf{T} y$$

par substitution arrière.

- plus stable que les normal equations;
- généralement moins coûteux que SVD;
- QR avec pivoting aide à détecter les colonnes redondantes;
- ne fournit pas aussi directement toutes les directions d'instabilité que SVD.

8 LU : résoudre des systèmes carrés efficacement

Objectif. Factoriser une matrice carrée générale une fois, puis résoudre rapidement un ou plusieurs systèmes $Ax = b$.

8.1 Définition et pivoting [P0/P1]

Pour $A \in \mathbb{R}^{d \times d}$ carrée et l'inconnue $x \in \mathbb{R}^d$, en pratique on utilise

$$\boxed{PA = LU}$$

où :

- $P \in \mathbb{R}^{d \times d}$ est une matrice de permutation pour choisir des pivots sûrs;
- $L \in \mathbb{R}^{d \times d}$ est triangulaire inférieure avec diagonale égale à 1;
- $U \in \mathbb{R}^{d \times d}$ est triangulaire supérieure.

Le pivoting partiel échange des lignes afin d'éviter de diviser par un pivot nul ou trop petit. Sans pivoting, LU peut échouer même lorsque A est inversible.

8.2 Résoudre un système linéaire [P0]

Pour un second membre $b \in \mathbb{R}^d$, puisque $PA = LU$:

$$Ax = b \iff LUx = Pb.$$

On effectue :

1. substitution avant : résoudre $Ly = Pb$ pour le vecteur intermédiaire y;

2. substitution arrière : résoudre $Ux = y$.

Exemple sans permutation :

$$A = \begin{pmatrix} 2 & 1 \\ 4 & 3 \end{pmatrix} = \underbrace{\begin{pmatrix} 1 & 0 \\ 2 & 1 \end{pmatrix}}_{L} \underbrace{\begin{pmatrix} 2 & 1 \\ 0 & 1 \end{pmatrix}}_{U}.$$

Pour $b = (5, 13)^\mathsf{T}$:

$$Ly = b \Rightarrow y = (5, 3)^\mathsf{T}, \qquad Ux = y \Rightarrow x = (1, 3)^\mathsf{T}.$$

8.3 À quoi LU sert réellement [P0/P1]

- résoudre un système carré général non singulier;
- réutiliser la factorisation pour beaucoup de seconds membres $b_1, \ldots, b_m$;
- calculer un déterminant via $\det(A) = \det(P) \prod_i U_{ii}$;
- résoudre des systèmes issus de calibrations, optimisations ou équations implicites.

La factorisation coûte $O(d^3)$; chaque nouveau second membre coûte seulement $O(d^2)$. LU n'est pas le choix naturel pour une régression rectangulaire ou un problème de rang déficient : utiliser QR ou SVD.

9 Cholesky et matrices de covariance

Objectif. Exploiter la structure symétrique définie positive pour obtenir une factorisation plus rapide et plus compacte que LU.

Si $A \in \mathbb{R}^{d \times d}$ vérifie $A = A^\mathsf{T} \succ 0$, c'est-à-dire si A est symétrique définie positive, alors

$$\boxed{A = LL^\mathsf{T}}$$

avec L triangulaire inférieure et diagonale positive.

Usages quant :

- résoudre $Ax = b$, avec $b, x \in \mathbb{R}^d$, lorsque A est une covariance régularisée ou une Hessienne SPD;
- pour $\mu \in \mathbb{R}^d$, simuler $z \sim \mathcal{N}(0, I_d)$ puis $x = \mu + Lz \sim \mathcal{N}(\mu, A)$;
- calculer efficacement un log-déterminant : $\log\det A = 2 \sum_i \log L_{ii}$;
- évaluer des vraisemblances gaussiennes sans former A^{-1}.

Une covariance empirique peut être singulière lorsque $p > n$, ou numériquement presque singulière. On peut utiliser shrinkage, ajouter τI_p avec $\tau > 0$, réduire la dimension ou employer SVD selon l'objectif.

10 Quel outil choisir ?

Objectif. Répondre à la question d'entretien importante : pourquoi cet algorithme plutôt qu'un autre ?

Problème	Choix	Avantage	Limite
$Ax = b$, A **carrée générale**	LU pivoté	rapide; réutilisable pour plusieurs b	exige non-singularité
$Ax = b$, $A \succ 0$	Cholesky	plus rapide, moitié du stockage	exige SPD
Least squares tall, rang plein	QR	stable et efficace	moins diagnostique que SVD
Rang déficient / pseudoinverse	SVD	solution robuste, rang explicite	plus coûteuse
Compression et facteurs	SVD/PCA	meilleure approximation linéaire de rang k	non supervisée
Régression instable	Ridge	réduit variance et conditionnement	introduit biais
Grande matrice creuse	Méthode itérative	évite la factorisation complète	diagnostic partiel

Décision rapide : structure SPD ⇒ Cholesky; système carré général ⇒ LU; least squares ⇒ QR; rang ou stabilité douteux ⇒ SVD.

10.1 Whitening [P1]

Avec $S = V\Lambda V^\top$, définir

$$Z_{white} = X_c V \Lambda^{-1/2}.$$

$\Lambda^{-1/2} = \mathrm{diag}(\lambda_1^{-1/2}, \ldots, \lambda_p^{-1/2})$ remet chaque composante principale à variance unitaire. Si les valeurs propres retenues sont strictement positives, la covariance empirique de Z_{white} est I_p. Cela peut aider une optimisation ou rendre les échelles comparables, mais $1/\sqrt{\lambda_i}$ amplifie les petites directions bruitées. Utiliser top-k whitening ou remplacer Λ par $\Lambda + \tau I_p$, $\tau > 0$, si nécessaire.

10.2 Coût, latence et production [P1]

- factoriser hors ligne et réutiliser lorsque la matrice change lentement;
- pour une nouvelle observation centrée $x_c \in \mathbb{R}^p$, calculer le score $z = V_k^\top x_c \in \mathbb{R}^k$ coûte environ $O(pk)$;
- contrôler les dimensions, la symétrie, le rang, κ_2 et les résidus numériques;
- tester le résidu relatif $\|Ax - b\|_2 / \|b\|_2$, l'erreur SVD $\|X - U\Sigma V^\top\|_F / \|X\|_F$ et l'orthogonalité $\|U^\top U - I_r\|_F$;
- préférer les bibliothèques BLAS/LAPACK aux implémentations manuelles en production;
- en rolling PCA, surveiller le drift du sous-espace et pas seulement les signes des eigenvecteurs.

11 Workflow appliqué à un projet quant

Objectif. Employer PCA/SVD sans fuite temporelle et vérifier qu'elles améliorent réellement la recherche.

1. définir observations, variables, timestamps et cible future;
2. construire X uniquement avec l'information disponible;
3. dans chaque fenêtre train : nettoyer, centrer, éventuellement standardiser;
4. ajuster PCA/SVD sur le train seulement;
5. choisir k par stabilité et validation chronologique;
6. transformer validation/test avec les paramètres du train;
7. comparer au modèle sans PCA et à une baseline simple;
8. contrôler performance, coûts, expositions factorielles et régimes;
9. en production : monitorer distributions, variance expliquée, reconstruction et PnL.

Si PCA améliore le backtest mais pas la validation walk-forward, elle a probablement capturé une covariance instable ou introduit une fuite. Si elle réduit le risque sans améliorer la prédiction, elle peut malgré tout être utile pour le sizing et la neutralisation.

12 Cheat sheet entretien

Objectif. Restituer rapidement les formules, les usages et le choix numérique.

Formules essentielles

Ici, EVR_i désigne le ratio de variance expliquée de la composante i, et $r = \mathrm{rank}(X)$ dans les formules SVD.

$$
\begin{aligned}
S &= X_c^\top X_c/(n-1),\\
Sv_i &= \lambda_i v_i,\\
Z &= X_c V_k,\\
\widehat{X} &= X_c V_k V_k^\top + \mathbf{1}_n \mu^\top,\\
\mathrm{EVR}_i &= \lambda_i / \sum_{j=1}^{p} \lambda_j,\\
X &= U\Sigma V^\top,\\
\lambda_i &= \sigma_i^2/(n-1),
\end{aligned}
\qquad
\begin{aligned}
X^+ &= V\Sigma^+ U^\top,\\
\widehat{\beta}_{OLS} &= V\Sigma^{-1}U^\top y,\\
\widehat{\beta}_{ridge} &= V\,\mathrm{diag}\left(\frac{\sigma_i}{\sigma_i^2+\lambda}\right)U^\top y,\\
\kappa_2(X) &= \sigma_{\max}(X)/\sigma_{\min}(X) \quad \text{si rang plein},\\
\kappa_2(X^\top X) &= \kappa_2(X)^2,\\
X &= QR, \quad R\widehat{\beta} = Q^\top y,\\
PA &= LU,\\
A &= LL^\top \quad (A \succ 0).
\end{aligned}
$$

Questions à maîtriser

1. Quel problème PCA résout-elle ?
2. Dériver $Sw = \lambda w$.
3. Scores contre loadings ?
4. Pourquoi centrer ? Quand standardiser ?
5. Pourquoi PCA minimise aussi la reconstruction ?
6. PCA peut-elle trouver de l'alpha ?
7. Comment neutraliser les premiers facteurs ?
8. Pourquoi les eigenvectors rolling changent-ils de signe ?
9. Que se passe-t-il si deux eigenvalues sont proches ?
10. Relier SVD et PCA.
11. Pourquoi éviter $X^\top X$?
12. Que signifie une petite singular value ?
13. Définir rang et condition number.
14. À quoi sert la pseudoinverse ?
15. Expliquer ridge dans la base SVD.
16. QR ou SVD pour least squares ?
17. Comment LU résout-il $Ax = b$?
18. Pourquoi faut-il pivoter dans LU ?
19. Quand préférer Cholesky à LU ?
20. Comment éviter le leakage avec PCA ?

Réponse-cadre : définir la matrice et ses dimensions; préciser la structure; nommer l'objectif mathématique; choisir la factorisation; éviter l'inverse explicite; discuter rang, conditionnement, coût et validation hors échantillon.