Séries temporelles financières

Révision ciblée Hedge Funds et Prop Firms

Synthèse du cours M2MO, recentrée sur les entretiens de quantitative research, systematic trading et market making. Les preuves académiques longues sont remplacées par les hypothèses, formules, intuitions, diagnostics et erreurs pratiques à connaître.

P0 À maîtriser et expliquer sans notes.

P1 À connaître conceptuellement et savoir appliquer.

P2 Utile seulement pour certains rôles ou comme approfondissement.

Objectif entretien : devant toute série, savoir définir la cible et l'horizon, diagnostiquer la dépendance et la non-stationnarité, proposer un modèle simple, valider chronologiquement, quantifier l'incertitude et vérifier que le signal survit aux coûts.

Contents

1 Carte des priorités **3**

2 Fondations : processus, rendements et stationnarité **3**
2.1 Processus temporel et information disponible [P0] . . . 3
2.2 Prix, rendements simples et log-rendements [P0] . . . 3
2.3 Stationnarité [P0] . . . 3
2.4 Bruit blanc, IID et différence de martingale [P0] . . . 4

3 Dépendance : autocovariance, ACF et PACF **4**
3.1 Ce que représente un lag [P0] . . . 4
3.2 ACF : dépendance totale avec le passé [P0] . . . 4
3.3 PACF : dépendance directe après contrôle des lags courts [P0] . . . 5
3.4 Exemple complet : pourquoi ACF et PACF diffèrent [P0] . . . 5
3.5 Comment les utiliser [P0] . . . 6
3.6 Intervalles graphiques et tests portemanteau [P0] . . . 6

4 Inférence sous dépendance **7**
4.1 Variance long terme et CLT [P0] . . . 7
4.2 Estimateur HAC / Newey-West [P0] . . . 7
4.3 Bootstrap temporel [P1] . . . 8

5 Tests de stationnarité et racines unitaires **8**
5.1 ADF : Augmented Dickey-Fuller [P0] . . . 8
5.2 KPSS [P0] . . . 8

6 AR, MA, ARMA et ARIMA **9**
6.1 Opérateur retard et notation [P0] . . . 9
6.2 AR(1) à connaître par coeur [P0] . . . 9
6.3 MA(1) [P0] . . . 9
6.4 ARIMA et différenciation [P0] . . . 10
6.5 Estimation et sélection [P0] . . . 10

7 Prévision et évaluation hors échantillon **10**
7.1 Prévision optimale [P0] . . . 10
7.2 Métriques [P0] . . . 10
7.3 Walk-forward validation [P0] . . . 11
7.4 Labels qui se chevauchent [P0] . . . 11
7.5 Checklist anti-leakage [P0] . . . 11

8 Volatilité conditionnelle **11**
8.1 Pourquoi GARCH ? [P0] . . . 11
8.2 GARCH(1,1) [P0] . . . 12
8.3 Extensions [P1] . . . 12
8.4 Volatilité réalisée et haute fréquence [P1] . . . 12

9 Cointegration et relative value **12**
9.1 Régression fallacieuse [P0] . . . 13

9.2 Cointegration [P0] . . . 13
9.3 Error-correction model [P0] . . . 13

10 Modèles espace-état et filtre de Kalman **13**
10.1 Modèle [P1] . . . 14
10.2 Étapes du filtre [P1] . . . 14

11 Régimes et ruptures structurelles **14**
11.1 Pourquoi c'est essentiel [P0] . . . 14
11.2 Approches [P1] . . . 15

12 Données haute fréquence et microstructure **15**
12.1 Pièges de données [P0 pour HFT/MM] . . . 15
12.2 Temps calendaire ou temps événementiel [P1] . . . 15
12.3 Lead-lag correctement testé [P0] . . . 15

13 Spectre, saisonnalité et mémoire longue **16**
13.1 Densité spectrale [P1/P2] . . . 16
13.2 Mémoire longue [P2] . . . 16

14 Signaux, modèles ML et backtests **16**
14.1 Construire correctement un dataset [P0] . . . 16
14.2 Signal et décision [P0] . . . 17
14.3 Pourquoi un modèle complexe peut échouer [P0] . . . 17

15 Workflow de recherche recommandé **17**

16 Cheat sheet entretien **17**

1 Carte des priorités

Objectif. Savoir quoi maîtriser pour un entretien HF/prop généraliste et quoi laisser en approfondissement.

P0	Rendements et transformations; stationnarité; bruit blanc; ACF/PACF; AR, MA, ARMA, ARIMA; GARCH; ADF, KPSS, Ljung-Box; prévision; walk-forward; leakage; coûts; HAC/Newey-West; cointegration; ruptures de régime.
P1	Kalman et modèles espace-état; volatilité réalisée; bootstrap par blocs; méthodes robustes; modèles à paramètres variables; traitement des données haute fréquence.
P2	Théorie spectrale détaillée; FARIMA et mémoire longue; mouvement brownien fractionnaire; preuves de stationnarité stricte; théorèmes généraux sur les processus affines causaux.

Ce qui a été volontairement réduit : estimation non paramétrique de tendance par noyau, preuves longues des théorèmes limites, décomposition de Wold, processus affines d'ordre infini et théorie formelle de la mémoire longue. Il faut reconnaître ces notions, pas les redémontrer pour un entretien QR/QT généraliste.

2 Fondations : processus, rendements et stationnarité

Objectif. Transformer les données de marché en une série correctement datée et suffisamment stable pour que l'estimation, la prévision et les tests aient un sens.

2.1 Processus temporel et information disponible [P0]

Une série temporelle est une collection $(X_t)_{t\in\mathbb{Z}}$ dont les observations sont ordonnées. La différence essentielle avec un échantillon IID est la dépendance temporelle.

La prévision à l'instant t doit utiliser uniquement l'information disponible :

$$\mathcal{F}_t = \sigma(X_t, X_{t-1}, \ldots, \text{autres données connues à } t).$$

Une cible correcte à l'horizon h est par exemple

$$Y_t = r_{t\to t+h} = \log P_{t+h} - \log P_t.$$

Réflexe : avant de parler de modèle, préciser le timestamp, l'horizon, la cible, la fréquence d'échantillonnage et ce qui était réellement connu au moment de la décision.

2.2 Prix, rendements simples et log-rendements [P0]

$$R_t = \frac{P_t - P_{t-1}}{P_{t-1}}, \qquad r_t = \log \frac{P_t}{P_{t-1}}.$$

Pour de petits mouvements, $r_t \approx R_t$. Les log-rendements sont additifs :

$$\log \frac{P_{t+h}}{P_t} = \sum_{j=1}^{h} r_{t+j}.$$

Les niveaux de prix sont souvent non stationnaires; les rendements sont souvent plus proches de la stationnarité. Cela ne veut pas dire que leur distribution est constante : volatilité, queues et corrélations peuvent varier dans le temps.

2.3 Stationnarité [P0]

La stationnarité permet d'utiliser le passé pour apprendre une relation supposée encore valable dans le futur. Sans elle, une moyenne, une variance ou un coefficient estimé sur tout l'historique peut ne rien représenter.

Stationnarité stricte : pour tous $k, t_1, \ldots, t_k$ et tout décalage h,

$$(X_{t_1}, \ldots, X_{t_k}) \overset{d}{=} (X_{t_1+h}, \ldots, X_{t_k+h}).$$

Stationnarité faible, ou d'ordre 2 :

$$\mathbb{E}[X_t] = \mu, \qquad \mathrm{Var}(X_t) = \gamma(0) < \infty, \qquad \mathrm{Cov}(X_t, X_{t-h}) = \gamma(h).$$

La covariance dépend du lag h, pas du temps calendaire t.

À retenir :

- stationnarité stricte + moments d'ordre 2 $\Rightarrow$ stationnarité faible;
- pour un processus gaussien, la stationnarité faible implique la stationnarité stricte;
- une rupture de moyenne, variance ou dynamique détruit la stationnarité globale;
- différencier peut retirer une racine unitaire, mais une différenciation excessive ajoute du bruit.

2.4 Bruit blanc, IID et différence de martingale [P0]

Ces notions servent à préciser ce qu'il reste à prévoir. Après un bon modèle de moyenne, on souhaite au minimum des résidus sans prévisibilité linéaire; ils ne sont pas nécessairement IID.

Un bruit blanc faible (ε_t) satisfait

$$\mathbb{E}[\varepsilon_t] = 0, \qquad \mathrm{Var}(\varepsilon_t) = \sigma^2, \qquad \mathrm{Cov}(\varepsilon_t, \varepsilon_{t-h}) = 0 \quad (h \neq 0).$$

Non-corrélé ne signifie pas indépendant. Un GARCH peut avoir $\mathrm{Corr}(r_t, r_{t-h}) = 0$ mais une forte dépendance dans r_t^2.

Une différence de martingale vérifie

$$\mathbb{E}[\varepsilon_t \mid \mathcal{F}_{t-1}] = 0.$$

Elle est imprévisible en moyenne avec l'information passée, condition plus utile en finance que la simple absence de corrélation linéaire.

3 Dépendance : autocovariance, ACF et PACF

Objectif. Détecter comment le passé est lié au présent, proposer un nombre de lags et vérifier qu'un modèle a retiré la dépendance linéaire exploitable.

3.1 Ce que représente un lag [P0]

Un **lag** est un décalage temporel. Pour une série quotidienne :

$$\text{lag } 1 = X_{t-1} \text{ (hier)}, \qquad \text{lag } 5 = X_{t-5} \text{ (cinq jours auparavant)}.$$

Au lag h, on aligne les couples

$$(X_{h+1}, X_1),\ (X_{h+2}, X_2), \ldots, (X_n, X_{n-h})$$

et l'on mesure si leurs valeurs évoluent ensemble. Par exemple, une ACF positive au lag 1 signifie qu'une valeur élevée aujourd'hui tend à être suivie d'une valeur élevée demain. Elle ne prouve ni causalité, ni rentabilité après coûts.

3.2 ACF : dépendance totale avec le passé [P0]

Pour un processus stationnaire centré :

$$\gamma(h) = \mathrm{Cov}(X_t, X_{t-h}), \qquad \rho(h) = \frac{\gamma(h)}{\gamma(0)} = \mathrm{Corr}(X_t, X_{t-h}).$$

La suite $\rho(1), \rho(2), \ldots$ est l'**autocorrelation function**, ou ACF. Chaque nombre répond à la question : *quelle est la corrélation totale entre la série actuelle et la même série décalée de h périodes ?*

À partir des données, on calcule :

$$\widehat{\gamma}(h) = \frac{1}{n}\sum_{t=h+1}^{n}(X_t - \bar{X})(X_{t-h} - \bar{X}), \qquad \widehat{\rho}(h) = \frac{\widehat{\gamma}(h)}{\widehat{\gamma}(0)}.$$

Exemple : $\widehat{\rho}(1) = 0.30$ signifie une corrélation empirique de 30% entre les couples (X_t, X_{t-1}). Cela ne signifie pas que 30% de X_t est « causé » par X_{t-1}.

3.3 PACF : dépendance directe après contrôle des lags courts [P0]

L'ACF peut contenir des effets **indirects**. Si X_{t-2} influence X_{t-1} et que X_{t-1} influence X_t, alors X_t et X_{t-2} peuvent être corrélés sans lien direct au lag 2.

Au lag 2, la PACF retire cet intermédiaire :

1. régresser X_t sur X_{t-1} et garder le résidu u_t;
2. régresser X_{t-2} sur X_{t-1} et garder le résidu v_{t-2};
3. calculer $\mathrm{Corr}(u_t, v_{t-2})$.

Ainsi,

$$\mathrm{PACF}(2) = \mathrm{Corr}\Big(X_t - \widehat{a}X_{t-1},\ X_{t-2} - \widehat{b}X_{t-1}\Big).$$

Plus généralement, la PACF au lag h contrôle les lags $1, \ldots, h-1$. Elle est aussi égale au dernier coefficient ϕ_h dans la régression AR(h) :

$$X_t = c + \phi_1 X_{t-1} + \cdots + \phi_h X_{t-h} + e_t.$$

Donc PACF(h) demande : *X_{t-h} apporte-t-il encore de l'information linéaire une fois les lags plus récents déjà inclus ?* À noter : $\mathrm{PACF}(1) = \mathrm{ACF}(1)$.

3.4 Exemple complet : pourquoi ACF et PACF diffèrent [P0]

Considérons

$$X_t = 0.7X_{t-1} + \varepsilon_t, \qquad \varepsilon_t \sim WN(0, \sigma^2).$$

En remplaçant récursivement X_{t-1} :

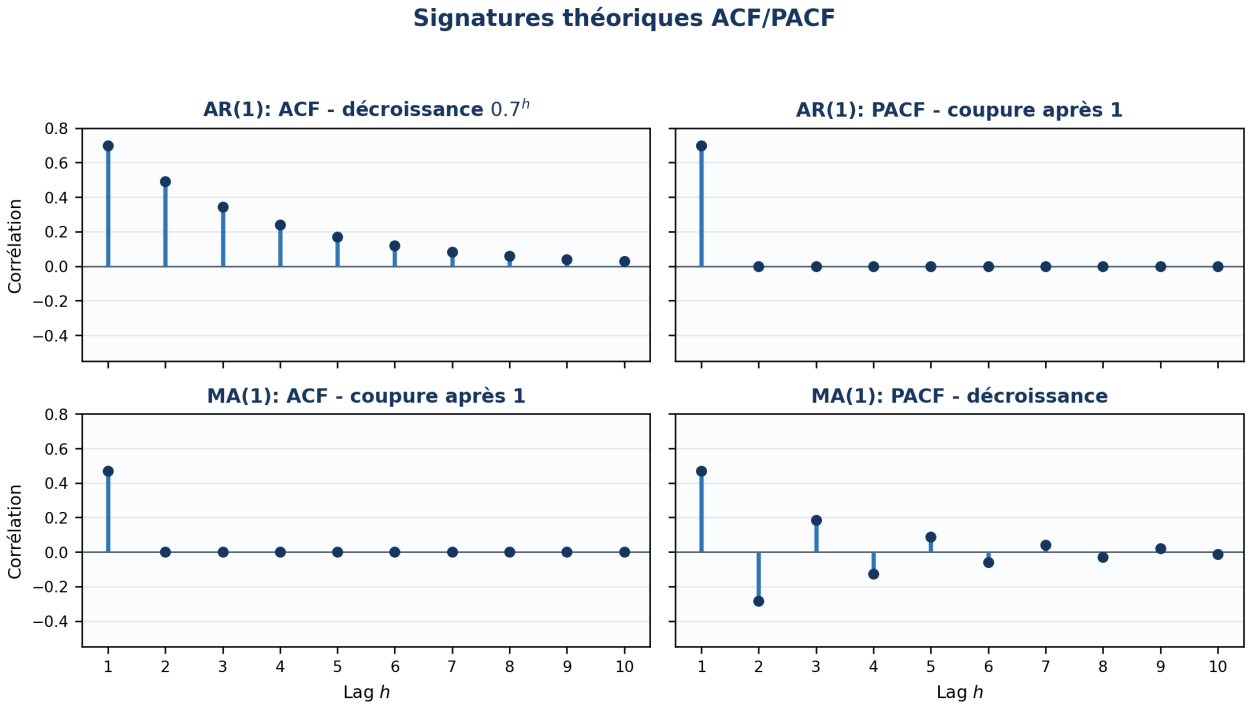
$$X_t = 0.7^2 X_{t-2} + 0.7\varepsilon_{t-1} + \varepsilon_t.$$

Ainsi, X_t et X_{t-2} sont corrélés, mais leur lien passe par X_{t-1}. On obtient :

$$\rho(h) = 0.7^h, \quad \rho(1) = 0.7, \quad \rho(2) = 0.49, \quad \rho(3) = 0.343.$$

En revanche, après contrôle de X_{t-1}, les lags plus anciens n'ajoutent rien :

$$\mathrm{PACF}(1) = 0.7, \qquad \mathrm{PACF}(h) = 0 \quad (h \geq 2).$$



Chaque barre correspond simplement à une valeur de la suite ACF ou PACF. Les graphiques montrent les valeurs **théoriques**; une estimation sur un échantillon réel sera bruitée.

3.5 Comment les utiliser [P0]

Modèle	ACF	PACF
AR(p)	décroît progressivement	coupure après p
MA(q)	coupure après q	décroît progressivement
ARMA(p,q)	décroît progressivement	décroît progressivement
Racine unitaire	décroissance très lente, proche de 1	grand premier lag
Saisonnalité	pics aux multiples de la période	structure saisonnière correspondante

- **Identifier un candidat :** une coupure de la PACF après p suggère AR(p); une coupure de l'ACF après q suggère MA(q).
- **Diagnostiquer un modèle :** l'ACF des résidus ne devrait plus contenir de structure significative.
- **Chercher la dynamique de volatilité :** regarder aussi l'ACF de r_t^2 et $|r_t|$.

Ces signatures sont des heuristiques, pas des preuves. On compare plusieurs spécifications, puis on contrôle les résidus et la performance hors échantillon.

3.6 Intervalles graphiques et tests portemanteau [P0]

Les bandes servent à repérer une autocorrélation isolée. Ljung-Box répond à une question plus utile : *les autocorrélations des lags* 1 *à* H *sont-elles collectivement compatibles avec zéro ?*

Sous un bruit blanc IID et pour un lag fixé,

$$\sqrt{n}\,\widehat{\rho}(h) \xrightarrow{d} \mathcal{N}(0,1).$$

Les bandes approximatives d'un correlogramme sont donc

$$\pm\frac{1.96}{\sqrt{n}}.$$

Tester beaucoup de lags séparément crée un problème de comparaisons multiples. Pour Ljung-Box :

$$H_0 : \rho(1) = \cdots = \rho(H) = 0, \qquad H_1 : \text{au moins une de ces autocorrélations est non nulle.}$$

La statistique agrège les autocorrélations estimées :

$$Q_{LB} = n(n+2)\sum_{h=1}^{H}\frac{\widehat{\rho}(h)^2}{n-h}.$$

Sous H_0 de bruit blanc, Q_{LB} est asymptotiquement χ^2_H. Après estimation d'un ARMA(p,q), on utilise souvent environ $H-p-q$ degrés de liberté.

Une petite p-value conduit à rejeter H_0 : il reste une structure temporelle et le modèle de moyenne est probablement incomplet. Ne pas rejeter signifie seulement que le test n'a pas détecté cette structure; cela ne prouve ni indépendance, ni absence de non-linéarité.

Appliquer Ljung-Box aux rendements détecte de la dépendance dans la moyenne. L'appliquer aux résidus standardisés au carré détecte une dynamique de variance manquante.

4 Inférence sous dépendance

Objectif. Mesurer correctement l'incertitude, les intervalles de confiance et les t-stats lorsque les observations temporelles ne sont pas indépendantes.

4.1 Variance long terme et CLT [P0]

Pour un processus stationnaire faiblement dépendant,

$$\sqrt{n}(\bar{X}-\mu) \xrightarrow{d} \mathcal{N}(0,\Omega),$$

où la variance long terme est

$$\boxed{\Omega = \gamma(0) + 2\sum_{h=1}^{\infty}\gamma(h) = 2\pi f(0).}$$

La variance IID $\gamma(0)$ est fausse si les observations sont autocorrélées. Une autocorrélation positive augmente généralement l'incertitude et réduit la taille d'échantillon effective.

Pour une structure approximativement AR(1),

$$n_{\text{eff}} \approx n\frac{1-\rho_1}{1+\rho_1}.$$

4.2 Estimateur HAC / Newey-West [P0]

Newey-West ne rend pas le signal meilleur : il corrige son erreur standard afin d'éviter une significativité artificiellement élevée sous hétéroscédasticité et autocorrélation.

Avec un truncation lag L et les poids de Bartlett $w_h = 1 - h/(L+1)$,

$$\widehat{\Omega}_{NW} = \widehat{\gamma}(0) + 2\sum_{h=1}^{L} w_h\widehat{\gamma}(h).$$

On l'utilise pour les erreurs standards de moyennes, régressions et alphas lorsque les résidus sont hétéroscédastiques et autocorrélés.

Question classique : « Pourquoi le t-stat d'une stratégie peut-il être trop élevé ? » Réponse : rendements autocorrélés, labels qui se chevauchent, volatilité variable, sélection après de nombreux essais et coûts ignorés. Les SE IID sous-estiment alors l'incertitude.

4.3 Bootstrap temporel [P1]

Le but est d'approximer la distribution d'un estimateur ou d'une métrique lorsque sa loi analytique est difficile à obtenir, tout en conservant la dépendance locale des données.

Le bootstrap IID casse la dépendance. Utiliser :

- **moving block bootstrap :** rééchantillonner des blocs contigus de longueur L;
- **stationary bootstrap :** blocs de longueur aléatoire géométrique;
- **cluster bootstrap :** rééchantillonner des journées ou actifs entiers si l'unité de dépendance est le groupe.

Le choix de L doit préserver la dépendance importante sans laisser trop peu de blocs indépendants. Le bootstrap sert à quantifier l'incertitude; il ne remplace pas l'ajout de lags lorsque ceux-ci sont des variables prédictives du modèle.

5 Tests de stationnarité et racines unitaires

Objectif. Décider si un niveau peut être modélisé directement, doit être différencié, ou exige une approche de cointegration ou de rupture structurelle.

5.1 ADF : Augmented Dickey-Fuller [P0]

ADF cherche une racine unitaire. Il sert notamment à éviter de régresser ou prévoir directement un niveau dont la dynamique n'est pas stable.

Régression type :

$$\Delta X_t = c + \delta t + \pi X_{t-1} + \sum_{j=1}^{p} \psi_j \Delta X_{t-j} + \varepsilon_t.$$

$$H_0 : \pi = 0 \quad \text{(racine unitaire)}, \qquad H_1 : \pi < 0 \quad \text{(stationnarité autour des termes déterministes)}.$$

Une petite p-value conduit à rejeter la racine unitaire. La statistique n'utilise pas les valeurs critiques ordinaires de Student. Il faut choisir correctement constante, tendance et nombre de lags.

5.2 KPSS [P0]

KPSS inverse la nullité d'ADF. Il sert à distinguer « ADF ne rejette pas par manque de puissance » d'une évidence plus convaincante contre la stationnarité.

$$H_0 : \text{stationnarité}, \qquad H_1 : \text{racine unitaire ou non-stationnarité}.$$

ADF et KPSS sont complémentaires :

ADF	KPSS	Lecture prudente
rejette	ne rejette pas	évidence en faveur de la stationnarité
ne rejette pas	rejette	évidence en faveur d'une racine unitaire
rejette	rejette	rupture, non-linéarité ou mauvaise spécification possible
ne rejette pas	ne rejette pas	test peu puissant ou échantillon insuffisant

Un test ne « prouve » jamais la stationnarité. Les ruptures de régime, tendances non linéaires et faibles échantillons peuvent tromper ADF et KPSS. Toujours regarder le graphe, les rolling moments et le contexte.

6 AR, MA, ARMA et ARIMA

Objectif. Construire un modèle linéaire parcimonieux de la dynamique conditionnelle, utile comme prévision simple, baseline et outil de diagnostic.

6.1 Opérateur retard et notation [P0]

Cette notation compacte permet de manipuler les lags et de lire immédiatement les conditions de stationnarité et d'invertibilité du modèle.

L'opérateur retard est $BX_t = X_{t-1}$. Un ARMA(p, q) s'écrit

$$\phi(B)(X_t - \mu) = \theta(B)\varepsilon_t,$$

avec

$$\phi(B) = 1 - \phi_1 B - \cdots - \phi_p B^p, \qquad \theta(B) = 1 + \theta_1 B + \cdots + \theta_q B^q.$$

Causal/stationnaire : les racines de $\phi(z) = 0$ sont à l'extérieur du cercle unité.

Invertible : les racines de $\theta(z) = 0$ sont à l'extérieur du cercle unité. L'invertibilité garantit une représentation unique des innovations à partir des observations.

6.2 AR(1) à connaître par coeur [P0]

L'AR(1) est le modèle minimal de persistance ou de retour vers la moyenne; il donne des prévisions et une demi-vie interprétables.

$$X_t = c + \phi X_{t-1} + \varepsilon_t, \qquad \varepsilon_t \sim WN(0, \sigma_\varepsilon^2).$$

Si $|\phi| < 1$:

$$\mu = \frac{c}{1-\phi}, \qquad \mathrm{Var}(X_t) = \frac{\sigma_\varepsilon^2}{1-\phi^2}, \qquad \rho(h) = \phi^{|h|}.$$

Prévision :

$$\widehat{X}_{t+h|t} = \mu + \phi^h (X_t - \mu).$$

Variance de l'erreur :

$$\mathrm{Var}(X_{t+h} - \widehat{X}_{t+h|t}) = \sigma_\varepsilon^2 \sum_{j=0}^{h-1} \phi^{2j} = \sigma_\varepsilon^2 \frac{1-\phi^{2h}}{1-\phi^2}.$$

Demi-vie du retour vers la moyenne :

$$h_{1/2} = \frac{\log(1/2)}{\log|\phi|}.$$

6.3 MA(1) [P0]

Le MA(1) modélise un choc qui affecte la série pendant une période supplémentaire; il sert aussi à reconnaître une ACF qui se coupe après le premier lag.

$$X_t = \mu + \varepsilon_t + \theta\varepsilon_{t-1}.$$

$$\gamma(0) = \sigma_\varepsilon^2(1+\theta^2), \qquad \gamma(1) = \theta\sigma_\varepsilon^2, \qquad \gamma(h) = 0 \quad (|h| > 1).$$

L'ACF se coupe après le lag 1. Le modèle est invertible si $|\theta| < 1$ avec cette convention de signe.

6.4 ARIMA et différenciation [P0]

ARIMA retire d'abord une tendance stochastique par différenciation, puis modélise la dynamique stationnaire restante.

Un ARIMA(p, d, q) vérifie

$$\phi(B)(1-B)^d X_t = \theta(B)\varepsilon_t.$$

Pour $d = 1$, on modélise $\Delta X_t = X_t - X_{t-1}$. En finance, modéliser les rendements revient souvent à différencier le logarithme des prix.

Risques :

- sous-différenciation : tendance résiduelle et racine unitaire;
- sur-différenciation : autocorrélation négative artificielle et variance accrue;
- une rupture structurelle peut ressembler à une racine unitaire.

6.5 Estimation et sélection [P0]

Le but est de choisir un modèle assez riche pour capturer la dynamique, mais assez simple pour rester stable hors échantillon. AIC/BIC comparent l'ajustement pénalisé; ils ne remplacent pas la validation temporelle.

Estimer ARMA/ARIMA par maximum de vraisemblance ou quasi-vraisemblance. Comparer :

$$\mathrm{AIC} = -2\ell(\widehat{\theta}) + 2k, \qquad \mathrm{BIC} = -2\ell(\widehat{\theta}) + k\log n.$$

AIC favorise souvent la qualité prédictive; BIC pénalise davantage et est consistant si le vrai modèle appartient à la famille candidate. En trading, la performance walk-forward prime sur les deux.

Après estimation, vérifier :

- racines de stationnarité/invertibilité;
- ACF des résidus et Ljung-Box;
- ACF des résidus au carré;
- stabilité des paramètres;
- performance hors échantillon après coûts.

7 Prévision et évaluation hors échantillon

Objectif. Vérifier si l'information disponible à t améliore réellement une décision future sur des périodes jamais utilisées pour ajuster le modèle.

7.1 Prévision optimale [P0]

Sous perte quadratique, la meilleure prévision utilisant $\mathcal{F}_t$ est

$$\boxed{\widehat{X}_{t+h|t} = \mathbb{E}[X_{t+h} \mid \mathcal{F}_t].}$$

Sous perte absolue, la prévision optimale est la médiane conditionnelle. Le choix de la loss doit correspondre à l'objectif économique : une erreur de prévision n'a pas toujours le même coût selon son signe ou sa taille.

7.2 Métriques [P0]

Une métrique sert à traduire l'objectif du modèle en critère mesurable. Elle doit correspondre à la décision économique plutôt qu'être choisie parce qu'elle donne le meilleur résultat.

- régression : MSE, RMSE, MAE, R^2 hors échantillon;
- direction : accuracy, mais comparer au taux de classe majoritaire;
- ranking : information coefficient (IC), rank IC;

- trading : PnL net, Sharpe, drawdown, turnover, capacité, hit rate et payoff ratio;
- probabiliste : log-loss, Brier score et calibration.

Une bonne MSE n'implique pas une stratégie profitable. Les erreurs importantes sont celles qui affectent les décisions, le sizing et les coûts.

7.3 Walk-forward validation [P0]

Le walk-forward reproduit la chronologie réelle : entraîner dans le passé, décider dans le futur, puis avancer la fenêtre. Il mesure donc mieux la performance déployable qu'un split aléatoire.

Ne jamais utiliser un split aléatoire standard pour une série temporelle.

Expanding window :

$$[1, t_1] \to (t_1, t_2], \quad [1, t_2] \to (t_2, t_3], \quad \dots$$

Rolling window :

$$[t_1 - W, t_1] \to (t_1, t_2], \quad [t_2 - W, t_2] \to (t_2, t_3], \quad \dots$$

Rolling s'adapte mieux aux régimes changeants; expanding utilise davantage de données si la relation est stable.

7.4 Labels qui se chevauchent [P0]

Cette vérification sert à empêcher qu'une même variation future apparaisse des deux côtés du split et à ne pas surestimer le nombre d'observations indépendantes.

Si

$$Y_t = \log P_{t+h} - \log P_t,$$

alors Y_t et Y_{t+1} partagent $h - 1$ rendements. Les observations ne sont pas indépendantes. Conséquences :

- erreurs standards IID trop faibles;
- fuite entre train et validation si les fenêtres se chevauchent;
- utiliser purge/embargo, sous-échantillonnage ou inference HAC adaptée.

7.5 Checklist anti-leakage [P0]

Le but est de garantir que le backtest n'utilise aucune information indisponible au moment exact de la décision.

- décaler chaque feature selon son heure réelle de publication;
- ajuster uniquement sur le train : scaler, PCA, imputation, sélection de variables;
- utiliser les données historiques disponibles à l'époque, sans révisions futures;
- construire l'univers avec les actifs réellement disponibles à chaque date;
- séparer validation pour hyperparamètres et test final;
- inclure spread, frais, slippage, impact, latence et contraintes de taille;
- ne pas choisir la meilleure période après avoir vu les résultats.

8 Volatilité conditionnelle

Objectif. Prévoir le risque qui varie dans le temps afin d'ajuster le sizing, les limites, les marges et la valorisation, même lorsque le rendement moyen est peu prévisible.

8.1 Pourquoi GARCH ? [P0]

Les rendements financiers ont souvent peu d'autocorrélation linéaire mais présentent :

- clustering de volatilité;
- autocorrélation de r_t^2 et $|r_t|$;

- queues épaisses;
- réaction asymétrique aux mauvaises nouvelles.

8.2 GARCH(1,1) [P0]

GARCH transforme les chocs passés en prévision récursive de variance; on l'utilise pour quantifier la persistance du risque et produire une volatilité conditionnelle future.

$$r_t = \mu_t + \sigma_t z_t, \qquad \sigma_t^2 = \omega + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2,$$

avec $\varepsilon_t = r_t - \mu_t$ et $\mathbb{E}[z_t^2] = 1$.

Contraintes usuelles :

$$\omega > 0, \qquad \alpha \geq 0, \qquad \beta \geq 0.$$

Pour une variance inconditionnelle finie :

$$\alpha + \beta < 1, \qquad \boxed{\bar{\sigma}^2 = \frac{\omega}{1-\alpha-\beta}.}$$

La persistance vaut $\alpha + \beta$. La demi-vie approximative d'un choc de variance est

$$h_{1/2} = \frac{\log(1/2)}{\log(\alpha+\beta)}.$$

Prévision à h pas :

$$\widehat{\sigma}_{t+h|t}^2 = \bar{\sigma}^2 + (\alpha+\beta)^{h-1}\left(\widehat{\sigma}_{t+1|t}^2 - \bar{\sigma}^2\right).$$

8.3 Extensions [P1]

Ces extensions servent à capturer les queues épaisses, l'asymétrie des chocs ou une volatilité latente que le GARCH gaussien symétrique représente mal.

- **Student-t innovations :** queues plus épaisses que la gaussienne;
- **GJR-GARCH :** terme $\gamma\varepsilon_{t-1}^2\mathbf{1}_{\{\varepsilon_{t-1}<0\}}$ pour l'effet levier;
- **EGARCH :** modélise $\log\sigma_t^2$, autorise naturellement l'asymétrie;
- **EWMA :** $\sigma_{t+1}^2 = \lambda\sigma_t^2 + (1-\lambda)r_t^2$;
- **stochastic volatility :** la volatilité latente possède sa propre innovation.

8.4 Volatilité réalisée et haute fréquence [P1]

La volatilité réalisée utilise les mouvements intrajournaliers pour mesurer la variance effectivement observée; elle sert de cible et de benchmark aux modèles de volatilité.

Avec des rendements intrajournaliers $r_{t,j}$,

$$RV_t = \sum_{j=1}^{M} r_{t,j}^2$$

est une estimation de la variance réalisée journalière. À fréquence trop élevée, bid-ask bounce, erreurs de prix et asynchronisme contaminent l'estimation. Utiliser sampling moins fin, subsampling, realized kernels ou estimateurs robustes au bruit de microstructure.

9 Cointegration et relative value

Objectif. Distinguer une relation d'équilibre stable entre niveaux non stationnaires d'une simple corrélation fallacieuse, puis construire un spread de relative value.

9.1 Régression fallacieuse [P0]

Ce diagnostic évite de prendre un R^2 ou un t-stat élevé pour un signal alors qu'il provient seulement de deux tendances non stationnaires.

Deux séries non stationnaires indépendantes peuvent produire un R^2 élevé et des t-stats significatifs. Avant une régression de niveaux, tester l'ordre d'intégration et la stationnarité des résidus.

Que signifie $I(d)$? $I(d)$ signifie *intégrée d'ordre d* : il faut différencier la série d fois pour obtenir une série stationnaire.

$$X_t \sim I(d) \quad \Longleftrightarrow \quad \Delta^d X_t \sim I(0), \qquad \Delta X_t = X_t - X_{t-1}.$$

Ainsi, $I(0)$ signifie stationnaire, tandis que $I(1)$ signifie non stationnaire en niveau mais stationnaire après une différence. Par exemple, la marche aléatoire $X_t = X_{t-1} + \varepsilon_t$ est $I(1)$ car $\Delta X_t = \varepsilon_t$ est stationnaire. Ici, I désigne l'ordre d'intégration, et non la matrice identité.

9.2 Cointegration [P0]

La cointegration recherche une combinaison stationnaire de séries non stationnaires; elle fournit une notion d'équilibre de long terme potentiellement exploitable en pair trading.

Deux séries $I(1)$, X_t et Y_t, sont cointegrées s'il existe β tel que

$$u_t = Y_t - \beta X_t$$

soit $I(0)$.

Procédure Engle-Granger :

1. vérifier que les niveaux sont compatibles avec $I(1)$;
2. estimer $Y_t = c + \beta X_t + u_t$;
3. tester une racine unitaire dans $\widehat{u}_t$ avec les valeurs critiques Engle-Granger;
4. vérifier stabilité, coûts et logique économique.

9.3 Error-correction model [P0]

L'ECM s'utilise lorsque des séries sont cointegrées. Il modélise leurs variations à court terme tout en imposant un rappel vers leur équilibre de long terme. Il sert à déterminer **quel actif corrige**, dans quelle direction et à quelle vitesse après un écart du spread.

$$\Delta Y_t = a + \lambda(Y_{t-1} - c - \beta X_{t-1}) + \sum_i \phi_i \Delta Y_{t-i} + \sum_j \psi_j \Delta X_{t-j} + \varepsilon_t.$$

Le terme $Y_{t-1} - c - \beta X_{t-1}$ est l'écart à l'équilibre observé à la date précédente. Si $\lambda < 0$, un écart positif réduit en moyenne ΔY_t : Y_t revient vers l'équilibre. Plus $|\lambda|$ est grand, plus la correction est rapide. L'ECM peut donc servir à prévoir le prochain ajustement et à mesurer la vitesse de mean reversion, sans faire une régression fallacieuse sur les niveaux.

Le spread de cointegration n'est toutefois pas automatiquement tradable : il faut une relation stable, une demi-vie exploitable, de la liquidité et des coûts faibles.

Pour un pair trade, utiliser le résidu estimé ou son z-score, pas simplement le ratio de prix. Recalibrer sans regarder le futur et vérifier que le hedge ratio ne change pas brutalement.

10 Modèles espace-état et filtre de Kalman

Objectif. Estimer en temps réel une quantité non directement observable et évolutive, comme une fair value, un bêta ou un hedge ratio.

10.1 Modèle [P1]

$$x_t = F_t x_{t-1} + w_t, \qquad w_t \sim \mathcal{N}(0, Q_t),$$
$$y_t = H_t x_t + v_t, \qquad v_t \sim \mathcal{N}(0, R_t).$$

x_t est l'état latent à estimer et y_t l'observation bruitée. F_t décrit l'évolution de l'état; H_t relie cet état à ce qui est observé. Q_t est la covariance du bruit de dynamique w_t et R_t celle du bruit de mesure v_t. Un Q_t élevé autorise l'état à changer vite; un R_t élevé conduit à moins faire confiance à la nouvelle observation. Exemples : fair value latente, tendance locale, beta dynamique ou hedge ratio variable.

Utilisation : choisir l'état utile au trading, estimer ou calibrer F_t, H_t, Q_t, R_t, puis mettre à jour $\widehat{x}_t$ à chaque nouvelle observation. Le résultat donne simultanément une estimation temps réel et son incertitude, utilisables pour une fair value, un hedge ou un seuil de risque.

10.2 Étapes du filtre [P1]

À chaque nouvelle observation, le filtre prédit l'état puis corrige cette prévision selon la précision relative du modèle et de la mesure.

$\widehat{x}_{t|s} = \mathbb{E}[x_t \mid y_1, \ldots, y_s]$ est l'état estimé avec l'information disponible jusqu'à s; $P_{t|s}$ est la covariance de son erreur d'estimation.

Prédiction :

$$\widehat{x}_{t|t-1} = F_t \widehat{x}_{t-1|t-1}, \qquad P_{t|t-1} = F_t P_{t-1|t-1} F_t^{\mathsf{T}} + Q_t.$$

Mise à jour :

$$K_t = P_{t|t-1} H_t^{\mathsf{T}} \left(H_t P_{t|t-1} H_t^{\mathsf{T}} + R_t \right)^{-1},$$
$$\widehat{x}_{t|t} = \widehat{x}_{t|t-1} + K_t (y_t - H_t \widehat{x}_{t|t-1}),$$
$$P_{t|t} = (I - K_t H_t) P_{t|t-1}.$$

Le terme $y_t - H_t \widehat{x}_{t|t-1}$ est l'**innovation** : la surprise apportée par la nouvelle donnée. Le gain K_t détermine la part de cette surprise intégrée à l'estimation; I est ici la matrice identité. Si la mesure est très bruitée (R_t grand), K_t diminue; si la prévision est incertaine ($P_{t|t-1}$ grand), K_t augmente. En pratique, on utilise $\widehat{x}_{t|t}$ comme estimation filtrée et $P_{t|t}$ pour quantifier sa confiance ou dimensionner une position. Sous hypothèses linéaires-gaussiennes, le filtre donne l'espérance conditionnelle exacte; sans normalité, il reste le meilleur estimateur linéaire sous les hypothèses de moments appropriées.

11 Régimes et ruptures structurelles

Objectif. Détecter qu'une relation historique s'est déplacée afin de recalibrer, réduire le risque ou arrêter une stratégie avant que l'ancien modèle ne devienne dangereux.

11.1 Pourquoi c'est essentiel [P0]

Un signal peut disparaître car moyenne, variance, liquidité, participants ou politique monétaire changent. Une relation stable in-sample peut être une moyenne artificielle de plusieurs régimes incompatibles.

Diagnostics :

- rolling mean, volatility, correlation, beta et Sharpe;
- stabilité des coefficients et des résidus;
- CUSUM ou tests de rupture;
- performance par sous-période, actif, pays et régime de volatilité;
- modèles à fenêtre glissante ou paramètres variables.

11.2 Approches [P1]

Ces méthodes localisent ou modélisent les changements; elles servent surtout à décider si le modèle reste valide, plutôt qu'à donner automatiquement un nouveau signal de trading.

- **Chow :** rupture à une date connue, hypothèses linéaires classiques;
- **CUSUM :** dérive cumulative des résidus;
- **change-point detection :** dates inconnues, pénalisation du nombre de ruptures;
- **Markov switching / HMM :** régime latent avec probabilités de transition;
- **online monitoring :** seuils sur drift des features, erreurs et PnL.

Ne pas choisir les régimes après avoir vu où la stratégie fonctionne : ce serait une nouvelle forme de data snooping.

12 Données haute fréquence et microstructure

Objectif. S'assurer qu'un signal apparent vient du marché et non des timestamps, du bid-ask, de l'asynchronisme ou d'une hypothèse d'exécution impossible.

12.1 Pièges de données [P0 pour HFT/MM]

- timestamps d'échange contre timestamps de réception locale;
- événements dans le mauvais ordre, latence variable et paquets perdus;
- trades et quotes asynchrones;
- prix stale, crossed markets et corrections;
- bid-ask bounce créant une autocorrélation négative des trade returns;
- survivorship et sélection des périodes liquides;
- barres de temps qui mélangent des quantités d'information très différentes.

12.2 Temps calendaire ou temps événementiel [P1]

Le choix de l'horloge sert à rendre les observations comparables : une seconde calme et une seconde contenant cent transactions ne portent pas la même quantité d'information.

On peut échantillonner par :

- intervalles de temps fixes;
- nombre de trades;
- volume ou dollar volume;
- événements de carnet.

Le choix change la distribution, la dépendance et l'interprétation du signal.

12.3 Lead-lag correctement testé [P0]

Le but est de vérifier qu'un mouvement de A fournit une information disponible assez tôt pour prévoir et trader B, et non de mesurer une simple réaction simultanée.

Pour tester si A prédit B :

$$\mathrm{Corr}(r_t^A, r_{t+h}^B)$$

où $h > 0$ est le délai de prévision. Une valeur non nulle signifie que le rendement de A observé à t est associé au rendement futur de B; elle ne prouve pas encore que le signal est exécutable. On estime cette corrélation, ou une régression de r_{t+h}^B sur l'information disponible à t, puis on vérifie le signe, la stabilité et le PnL hors échantillon.

Vérifier : synchronisation des horloges, stabilité par période, liquidité, latence exécutable, significativité avec dépendance, et PnL après coûts. Une corrélation simultanée n'est pas une prédiction tradable.

13 Spectre, saisonnalité et mémoire longue

Objectif. Décrire la dépendance par fréquence plutôt que par lag afin de détecter cycles, saisonnalités et persistance très lente.

13.1 Densité spectrale [P1/P2]

Le spectre sert à identifier les fréquences qui contribuent le plus à la variance et à repérer une périodicité que l'ACF seule peut rendre moins lisible.

Pour un processus stationnaire,

$$f(\omega) = \frac{1}{2\pi} \sum_{h=-\infty}^{\infty} \gamma(h) e^{-ih\omega}.$$

Ici, $\gamma(h) = \mathrm{Cov}(X_t, X_{t-h})$, ω est une fréquence angulaire et $f(\omega)$ la variance portée autour de cette fréquence. En pratique, on estime f par un periodogramme lissé. Un pic en ω suggère un cycle de période approximative $2\pi/\omega$ observations : on peut alors créer une feature saisonnière, désaisonnaliser la série ou vérifier qu'un signal ne vient pas d'un cycle mécanique. Un periodogramme brut est très bruité; lisser ou moyenner est nécessaire.

À retenir :

$$\Omega = 2\pi f(0)$$

est la variance long terme. Elle sert notamment à calculer l'incertitude de la moyenne sous dépendance :

$$SE(\overline{X}_n) \approx \sqrt{\Omega/n}.$$

13.2 Mémoire longue [P2]

Cette notion sert à reconnaître une dépendance qui disparaît beaucoup plus lentement qu'un ARMA classique; elle modifie l'incertitude à long horizon et la taille d'échantillon effective.

Une mémoire longue typique satisfait

$$\gamma(h) \sim Ch^{-\delta}, \qquad 0 < \delta < 1,$$

où $C > 0$ règle l'amplitude et δ la vitesse de décroissance : plus δ est petit, plus la dépendance persiste. Les autocovariances ne sont alors pas sommables et les erreurs standards IID sous-estiment souvent l'incertitude. FARIMA modélise cette persistance avec $(1-B)^d$, où $BX_t = X_{t-1}$ est l'opérateur retard et $0 < d < 1/2$ le paramètre de différenciation fractionnaire. On l'utilise lorsque l'ACF décroît trop lentement pour un ARMA, après avoir éliminé tendances et ruptures qui peuvent imiter la mémoire longue.

Le Hurst exponent peut être trompé par tendances, ruptures et échantillons courts. Pour un entretien généraliste, savoir définir et expliquer la lente décroissance suffit.

14 Signaux, modèles ML et backtests

Objectif. Passer d'une prédiction statistique à une règle de trading exécutable, validée chronologiquement et rentable après coûts.

14.1 Construire correctement un dataset [P0]

Le dataset doit reproduire exactement ce que le modèle aurait vu et ce qu'il aurait tenté de prévoir à chaque date.

Pour chaque temps t :

$$X_t = \text{features connues à } t, \qquad Y_t = r_{t\to t+h} \text{ ou une autre cible future.}$$

h est l'horizon économique de la prédiction. Choisir h en fonction du temps de détention et des coûts; si les cibles se chevauchent, purger ou espacer les observations pour ne pas surestimer la quantité d'information.

Exemples de features : lags, rolling mean/volatility, imbalance, spread, volume, momentum, carry, funding, basis et variables cross-asset. Toute fenêtre doit finir au plus tard à t.

14.2 Signal et décision [P0]

Cette étape convertit une prévision en direction, seuil d'entrée et taille de position; un score prédictif seul n'est pas encore une stratégie.

Le modèle estime

$$\widehat{\mu}_t = \mathbb{E}[Y_t \mid X_t]$$

ou une probabilité $\widehat{p}_t$. Une règle économique simple est

$$\text{trader si } |\widehat{\mu}_t| > \widehat{\text{coût}}_t + \text{marge de sécurité.}$$

Le signe donne la direction; la magnitude, l'incertitude, la volatilité, la liquidité et les limites de risque déterminent la taille. Utiliser des seuils d'entrée et de sortie différents peut réduire le turnover.

14.3 Pourquoi un modèle complexe peut échouer [P0]

Cette analyse sert à distinguer un gain statistique réel d'un modèle qui apprend le bruit, un régime particulier ou une imperfection du backtest.

- ratio signal/bruit extrêmement faible;
- non-stationnarité et changement de régime;
- nombreuses features corrélées et peu d'observations effectivement indépendantes;
- optimisation répétée sur le même jeu de test;
- coûts non linéaires et capacité limitée;
- modèle apprenant un timestamp, un actif ou une période plutôt qu'un mécanisme stable.

Toujours commencer par un baseline : moyenne historique, random walk, AR simple, EWMA ou régression linéaire.

15 Workflow de recherche recommandé

Objectif. Organiser une recherche reproductible où chaque résultat peut être expliqué, contesté, déployé et arrêté.

1. **Hypothèse économique :** pourquoi l'effet devrait-il exister et qui paie ?
2. **Données :** provenance, timestamps, corrections, univers et disponibilité historique.
3. **Cible :** variable, horizon et unité.
4. **Exploration :** distributions, missing values, ACF, saisonnalité, ruptures et outliers.
5. **Baseline :** modèle simple et règle de trading transparente.
6. **Validation :** rolling/expanding, purge, embargo et test final intact.
7. **Inférence :** HAC ou bootstrap adapté, multiples essais et incertitude des métriques.
8. **Économie :** coûts, turnover, slippage, impact, capacité et contraintes.
9. **Robustesse :** sous-périodes, actifs, paramètres, régimes et délais artificiels.
10. **Déploiement :** data validation, monitoring, limites, kill switch et critères de retrait.

16 Cheat sheet entretien

Objectif. Réviser rapidement les formules, les diagnostics et les réponses courtes à restituer sans notes.

Formules à connaître

$$\begin{aligned} r_t &= \log(P_t/P_{t-1}), \\ \rho(h) &= \gamma(h)/\gamma(0), \end{aligned}$$

$$
\begin{aligned}
\Omega &= \gamma(0) + 2\sum_{h\geq 1}\gamma(h) = 2\pi f(0),\\
X_t &= c + \phi X_{t-1} + \varepsilon_t,\\
\mu_{AR(1)} &= c/(1-\phi),\\
\mathrm{Var}(X_t) &= \sigma_\varepsilon^2/(1-\phi^2),\\
\widehat{X}_{t+h|t} &= \mu + \phi^h(X_t - \mu),\\
Q_{LB} &= n(n+2)\sum_{h=1}^{H}\widehat{\rho}(h)^2/(n-h),\\
\sigma_t^2 &= \omega + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2,\\
\bar{\sigma}^2 &= \omega/(1-\alpha-\beta),\\
u_t &= Y_t - c - \beta X_t,\\
\mathrm{AIC} &= -2\ell + 2k, \qquad \mathrm{BIC} = -2\ell + k\log n.
\end{aligned}
$$

À quoi servent ces formules ?

- r_t : construire une série de rendements plus proche de la stationnarité.
- $\rho(h)$: mesurer la dépendance au lag h.
- Ω : corriger l'incertitude d'une moyenne pour l'autocorrélation.
- AR(1) : baseline de dynamique et de mean reversion.
- $\mu_{AR(1)}$ et $\mathrm{Var}(X_t)$: niveau et risque de long terme si $|\phi| < 1$.
- $\widehat{X}_{t+h|t}$: produire une prévision à horizon h.
- Q_{LB} : tester si des autocorrélations subsistent jusqu'au lag H.
- GARCH : prévoir la variance conditionnelle du prochain rendement.
- $\bar{\sigma}^2$: niveau de variance vers lequel GARCH revient si $\alpha + \beta < 1$.
- u_t : construire et tester un spread de cointegration.
- AIC/BIC : comparer des modèles estimés sur les mêmes données; plus petit est préférable.

Dans AIC/BIC, ℓ est la log-vraisemblance maximisée, k le nombre de paramètres et n le nombre d'observations. Le BIC pénalise davantage la complexité lorsque n augmente.

Questions à savoir traiter rapidement

1. Pourquoi modélise-t-on souvent les rendements plutôt que les prix ?
2. Différence entre stationnarité stricte, faible et racine unitaire ?
3. Un bruit blanc est-il nécessairement indépendant ?
4. Comment distinguer AR(p) et MA(q) avec ACF/PACF ?
5. Conditions de stationnarité et prévision d'un AR(1) ?
6. Pourquoi les erreurs standards IID échouent-elles sur une série autocorrélée ?
7. Que testent ADF, KPSS et Ljung-Box ?
8. Pourquoi appliquer Ljung-Box aussi aux résidus au carré ?
9. Que signifie $\alpha + \beta$ dans un GARCH(1,1) ?
10. Pourquoi deux prix non stationnaires peuvent-ils donner une régression fallacieuse ?
11. Définir cointegration et error correction.
12. Rolling window contre expanding window : quel compromis ?
13. Pourquoi les labels qui se chevauchent gonflent-ils les t-stats ?
14. Comment éviter look-ahead, survivorship et leakage de preprocessing ?
15. Comment tester un lead-lag sans confondre simultanéité et prédiction ?
16. Pourquoi une meilleure MSE ne garantit-elle pas un meilleur PnL ?
17. Comment détecter qu'un signal a changé de régime ?
18. Quel est le rôle du gain de Kalman ?
19. Pourquoi la volatilité réalisée devient-elle bruitée à très haute fréquence ?
20. Comment décider si un signal mérite réellement d'être tradé ?

Réponse-cadre à une question ouverte : définir l'information disponible et l'horizon; vérifier stationnarité et dépendance; proposer un baseline; choisir une validation chronologique; mesurer l'incertitude avec une méthode compatible avec la dépendance; ajouter les coûts; tester la stabilité; expliquer comment le modèle serait monitoré et arrêté.